

Literatür Taraması

Konu: Mental Health Detection and Classification Using Classical Machine Learning, LSTM-based Deep Learning, and BERT Models

Giriş

Ruh sağlığı bozuklukları günümüzde dünya genelinde milyonlarca insanı etkileyen ciddi bir halk sağlığı sorunudur. Dünya Sağlık Örgütü (WHO) verilerine göre her 8 kişiden 1'i bir tür mental sağlık bozukluğuyla yaşamaktadır; depresyon ve anksiyete en yaygın görülen durumlar olup COVID-19 pandemisiyle birlikte bu oranlar belirgin biçimde artmıştır.

Geleneksel tanı yöntemleri klinik görüşmeler ve standart anketlere dayanmakla birlikte, bu yöntemler zaman alıcı, pahalı ve subjektif değerlendirmeye açık olmaları nedeniyle erken teşhis için yetersiz kalmaktadır. Sosyal medya platformlarının hızla yaygınlaşmasıyla birlikte Twitter, Reddit ve Facebook gibi platformlarda paylaşılan metin verileri, bireylerin ruh hallerini, duygularını ve mental durumlarını yansıtan zengin bir kaynak haline gelmiştir.

Bu bağlamda, sosyal medya verilerinden mental sağlık bozukluklarını tespit etmek ve sınıflandırmak amacıyla Doğal Dil İşleme (NLP) ve makine öğrenimi yöntemlerinin kullanımına yönelik araştırmalar büyük ivme kazanmıştır. Bu literatür taraması; klasik makine öğrenimi algoritmaları (LR, SVM), derin öğrenme mimarileri (BiLSTM) ve transformer tabanlı modeller (MentalBERT, MentalRoBERTa) kullanılarak mental sağlık tespiti üzerine yürütülen 15 akademik çalışmayı kapsamaktadır.

İncelenen Makaleler ve Özetleri

Bin Saeed & Cha (2025) [1] Multi-modal Deep-Attention-BiLSTM Based Early Detection of Mental Health Issues Using Social Media Posts

Bu çalışma, Reddit platformundan elde edilen sosyal medya gönderilerini kullanarak depresyon, anksiyete, bipolar bozukluk ve şizofreni gibi çeşitli mental sağlık durumlarının erken tespitine odaklanmaktadır. Mevcut yaklaşımların yalnızca metinsel özelliklere odaklanmasının sınırlılığınan

hareketle, arařtırmacılar hem dilsel hem de zamansal özellikleri bir arada modelleyen DABLNet adlı çok modlu derin öğrenme mimarisi önermişlerdir.

DABLNet mimarisi üç temel bileşenden oluşmaktadır: metin içeriğini işleyen Çift Yönlü LSTM (BiLSTM) modülü, gönderilerin zaman damgası bilgilerini işleyen LSTM modülü ve bu iki kaynaktan gelen temsilleri dinamik olarak birleştiren çapraz modal dikkat (cross-modal attention) mekanizması. Model, metin temizleme, zamansal özellik ölçeklendirme ve etiket kodlama adımlarından oluşan ön işleme hattıyla hazırlanan etiketli Reddit gönderileri üzerinde eğitilmiş ve değerlendirilmiştir.

Deneyisel sonuçlar, DABLNet'in zamansal dinamikleri de göz önünde bulundurmayan geleneksel modellerle kıyaslandığında %75.96 test doğruluğu ve 0.7376 F1 skoru elde ettiğini ortaya koymaktadır. Bu bulgular, metin içeriğinin yanı sıra geride kalma zamanları ve aktivite örüntüleri gibi davranışsal zaman bilgilerinin mental sağlık tespitinde anlamlı ek bilgi sağladığını göstermektedir.

Zhou & Mohd (2025) Mental Health Safety and Depression Detection in Social Media Text Data[2]

Bu araştırma, sosyal medyada yaygın olarak kullanılan emoji, argo ve bağlam bağımlı ifadeler gibi gayri resmi dil unsurlarını ele almanın önemine dikkat çekmektedir. Geleneksel depresyon tespit yöntemlerinin bu tür dil yapılarını işlemede yetersiz kaldığı değerlendirilerek, çalışmada gelişmiş metin ön işleme ile derin öğrenme modelini entegre eden yeni bir çerçeve önerilmektedir.

Önerilen yöntemin temel katkısı, emoji sembollerini metne dönüştüren emoji normalizasyonu ve özel bir sözlükle argo ifadeleri standart biçimlere çeviren ön işleme hattıdır. Ayrıca metindeki depresyonla ilişkili duygusal ipuçlarını belirlemek amacıyla duygu skorları ek özellik olarak kullanılmaktadır. Sınıflandırma için BERT'in bağlamsal gömme vektörleri ile BiLSTM'in sıralı işleme kapasitesini birleştiren BERT-BiLSTM modeli kullanılmaktadır.

Önerilen yaklaşım; doğruluk, hassasiyet, duyarlılık, F1-skoru ve AUC ölçütlerinde temel (baseline) modellerden üstün sonuçlar sergilemiş, özellikle gayri resmi sosyal medya metinlerinde depresyon tespiti için yeni bir referans noktası oluşturmuştur.

Karamat et al. (2024-2025) A Hybrid Transformer Architecture for Multiclass Mental Illness Prediction Using Social Media Text [3]

Bu çalışma, genel amaçlı dil modellerinin ve geleneksel gömme tekniklerinin mental sağlık metinlerindeki metaforik ve nüanslı ifadeleri yeterince yakalayamadığı sorununu ele almaktadır. Bu sınırlılığı aşmak amacıyla araştırmacılar, alana özgü iki ön eğitilmiş dil modeli olan MentalBERT ve MelBERT'i CNN katmanlarıyla birleştiren hibrit bir transformer mimarisi önermektedir.

MentalBERT, mental sağlıkla ilgili büyük ölçekli metin verileri üzerinde ön eğitim almış olup alana özgü dilsel ve anlamsal örüntüleri yakalamaktadır. MelBERT ise metaforik ifadeleri daha iyi anlamak için büyük ölçekli metafor içerikli verilerle ön eğitim almıştır. Bu iki modelden elde edilen gömme vektörleri, derin özellik çıkarımı için CNN katmanlarıyla ardışık olarak işlenmekte ve birleştirilmektedir.

Hibrit mimari; depresyon, anksiyete, stress, yeme bozuklukları ve bağımlılık davranışları gibi çok sayıda mental bozukluğu içeren veri setinde %92 genel doğruluk ve %92 F1 skoru elde etmiştir. Bu sonuçlar, alana özgü transformer modellerinin genel amaçlı modellerle kıyaslandığında mevcut en iyi yöntemleri geçtiğini ortaya koymaktadır.

Hussain et al. (2025) Multi-Level Depression Severity Detection with Deep Transformers and Enhanced Machine Learning Techniques [4]

Bu çalışma, depresyonun yalnızca varlığını değil, şiddetini de tahmin etmeye odaklanmaktadır. Reddit'ten derlenen ve minimum, hafif, orta ve şiddetli olmak üzere dört düzeyde etiketlenmiş gönderilerden oluşan veri seti kullanılarak, Lojistik Regresyon, SVM, Naive Bayes, Random Forest, XGBoost ve Gradient Boosting dahil 10 klasik ML algoritması ve BERT, RoBERTa, XLM-RoBERTa, MentalBERT, BioBERT, RoBERTa-large, DistilBERT, DeBERTa, Longformer ve ALBERT dahil 10 transformer modeli kapsamlı biçimde değerlendirilmiştir.

ML modelleri için Word2Vec ve GloVe gömme yöntemleri denenmiş; en iyi sonuç GloVe gömmeleri kullanan XGBoost modeli tarafından F1 skoru 94.01 ile elde edilmiştir. Transformer modelleri arasında ise MentalBERT 97.31 F1 skoru ile en yüksek performansı sergilerken RoBERTa (96.27) ve RoBERTa-large (96.14) bunu takip etmiştir.

Çalışmanın en önemli bulgusu, alana aktarım yapılmış transformer modellerinin (MentalBERT gibi) hem klasik ML yöntemlerini hem de genel amaçlı transformer modellerini belirgin biçimde geçtiğini göstermesidir. Bu durum,

ince taneli mental sađlık izlemesi iin alana zg n eđitimi modellerin kritik nemine iřaret etmektedir.

Islam et al. (2018) Depression Detection from Social Network Data Using Machine Learning Techniques [5]

Bu alıřma, alandaki erken dnem klasik makine đrenimi uygulamalarından birini temsil etmekte ve referans/karřılařtırma noktası olarak nem tařıtmaktadır. Arařtırmacılar, bipolar bozukluk, depresyon ve anksiyete sayfalarından derlenen Facebook kullanıcı yorumlarını analiz etmek amacıyla LIWC (Linguistic Inquiry and Word Count) aracıyla psikodilbilimsel zellikler ıkarmıřtır.

Duygusal sreler (pozitif/negatif duygular), zamansal sreler (gemiř/řimdiki/gelecek zaman odađı) ve dilbilimsel zellikler (kiřisel zamirler, olumsuzlama) gibi drt ana zellik grubu tanımlanmıřtır. Karar Ađacı, SVM, KNN ve Ensemble yntemleri karřılařtırmalı olarak deđerlendirilmiř; Karar Ađacı diđer tm klasik ML yntemlerini geride bırakarak en yksek dođruluđu elde etmiřtir.

Bu arařtırma, sosyal medya verisi ile psikodilbilimsel zellik mhendisliđinin depresyon tespitinde etkili bir yaklařım sunduđunu ortaya koymuřtur. Transformer ve derin đrenme modellerinin hl kıyaslama temeli olarak kullanıldıđı gz nne alındıđında, mevcut alıřmalara gl bir metodolojik bađlam sađlamaktadır.

Wagay et al. (2025) MentalRoBERTa-Caps: A Capsule-Enhanced Transformer Model for Mental Health Classification [6]

Bu alıřma, byk dil modellerinin (BERT, RoBERTa) yksek dođrulukla birlikte getirdiđi hesapsal maliyet sorununu ele almaktadır. Arařtırmacılar, gerek zamanlı uygulamalar ve kaynak kısıtlı ortamlar iin uygun, hafif ve verimli bir mimari tasarlamayı hedeflemektedir.

nerilen MentalRoBERTa-Caps modeli, 6 katmanlı hafifletilmiř bir RoBERTa kodlayıcısını Kapsl Ađı sınıflandırma katmanıyla birleřtirmektedir. RoBERTa tarafından retilen bađlamsal gmme vektrleri birincil kapsllere dnřtrlmekte, dinamik ynlendirme mekanizması ise st dzey soyutlamaları yakalayan sınıf kapsl ıktıları retmektedir. Model yorumlanabilirliđi iin LIME (Local Interpretable Model-Agnostic Explanations) kullanılmaktadır.

Model, benchmark mental sađlık veri setleri üzerinde yu00fcksek dođruluk sergilerken tam o0l0ekli transformer modellerine kıyasla 0ıkarım s0uresini belirgin o0l0u0de azaltmaktadır. Zaman karmaşıklıđı analizi, bu 0alıřmanın verimlilik-dođruluk dengesini sistematik bi0imde ele alan ender 0alıřmalardan biri olduđunu ortaya koymaktadır.

Sanchez Rodriguez et al. (2026) Understanding Mental Health Discourse on Reddit with Transformers and Explainability [7]

Bu 0alıřma, Reddit'teki mental sađlık topluluklarının hedeflenen konulara ne o0l0u0de odaklandıđını deđerlendirerek; kullanıcıların bu platformlarda nasıl konuřtuđunu anlamlandırmayı ama0lamaktadır. Arařtırma, anksiyete, depresyon, bipolar bozukluk ve Sınır Kiřilik Bozukluđu (BPD) subredditlerini inceleyen d0rt sınıflı bir sınıflandırma problemi olarak kurgulanmıřtır.

0alıřmada fine-tuned BERT ve MentalBERT modelleri kullanılmıř; LIME ile a0ıklanabilirlik analizi ger0ekleřtirilmiřtir. MentalBERT, BERT'i hafif bi0imde geride bırakarak ortalama %82 dođruluk elde etmiřtir. LIME analizleri, farklı bozukluklar i0in dilsel kalıpları bařarıyla ortaya koymuřtur: bipolar bozukluk tartıřmalarında duygu kararsızlıđına iliřkin dil, BPD topluluklarında ise duygusal d0zenleme g0u0luđu0ne deđinen ifadeler 0n plana 0ıkmaktadır.

0alıřmanın en deđerli katkılarından biri, tek tanı veya ikili sınıflandırma odaklı 0nceki 0alıřmaların aksine, birden fazla iliřkili mental sađlık durumunu aynı anda ele alan dengeli ve 0ok sınıflı bir sınıflandırma yaklařımı sunmasıdır.

Xin & Zakaria (2024) Integrating BERT with CNN and BiLSTM for Explainable Detection of Depression [8]

Bu 0alıřma, depresyon tespitinde iki temel sorunu ele almaktadır: sınırlı etiketli veri ve model řeffaflıđının yetersizliđi. BERT'in bađlamsal zenginliđini CNN ve BiLSTM ile birleřtiren hibrit modeller 0nerilmekte; bu modeller a0ıklanabilirlik teknikleriyle desteklenmektedir.

0u0 farklı veri seti kullanılmıřtır: Depression Reddit Dataset, Mental Health Corpus ve Sentiment Analysis for Tweets Dataset. BERT, BERT-BiLSTM ve BERT-CNN modelleri birbirleriyle ve MentalBERT ile karřılařtırılmıřtır. Karar verme s0urecini g0rselleřtirmek i0in Transformer Interpretability Beyond Attention Visualization (TIAV) ve Average Attention Weight (AAW) y0ntemleri kullanılmıřtır.

BERT-CNN, Depression Reddit Dataset'te %98.2, Mental Health Corpus'ta %96.1 ve Sentiment Analysis for Tweets Dataset'te %100 olmak üzere en yüksek doğruluk skorlarına ulaşmıştır. Dikkat haritası görselleştirmeleri, depresyonla ilişkili kilit dil örüntülerini ve özellikleri başarıyla açığa çıkarmıştır.

Tahir et al. (2025) Depression Detection in Social Media: A Comprehensive Review[9]

Bu kapsamlı derleme makalesi, Ocak 2018 ile Temmuz 2024 tarihleri arasında sosyal medya üzerinden depresyon tespitine yönelik gerçekleştirilen makine öğrenimi ve derin öğrenme çalışmalarını sistematik biçimde ele almaktadır. Çalışma; metodoloji gelişiminin izlenmesi, veri setlerinin belirlenmesi ve analiz edilmesi ile genel bir mimari pipeline'ın ortaya konması gibi kritik boşlukları kapatmayı hedeflemektedir.

İnceleme, alandaki gelişimi üç dönemde ele almaktadır: SVM, DT ve RF gibi özellik mühendisliğine dayalı klasik ML modellerinin hâkim olduğu erken dönem; RNN, CNN ve LSTM'in öne çıktığı derin öğrenme dönemi; ve BERT ile türevlerinin belirleyici hale geldiği transformer çağı. Çalışma ayrıca veri gizliliği, veri güvenilirliği ve model önyargısı gibi etik konuları da ele almaktadır.

Bu derleme, yapılan literatür taramasına önemli bağlam sağlamakta; sosyal medya tabanlı depresyon tespitinde alan genelindeki eğilimler ve açık araştırma soruları hakkında kapsamlı bir bakış açısı sunmaktadır.

Thamrin & Chen (2024) Detection of Bipolar Disorder on Social Media Data Utilizing Domain Fine-Tuned Word Embeddings[10]

Bu çalışma, sıkça karıştırılan iki mental sağlık bozukluğu olan bipolar bozukluk (BD) ile depresyonu birbirinden ayırt etme sorununu ele almaktadır. Bipolar bozukluğun depresyon epizotlarını da kapsaması nedeniyle bu iki durum sıklıkla yanlış teşhis edilmektedir.

Araştırmada BERT, BioBERT, ClinicalBERT ve MentalBERT gibi farklı alan spesifik ön eğitilmiş modeller karşılaştırmalı olarak incelenmiştir. Çalışma, biyomedikal, klinik ve mental sağlık alanına ait ince ayar bilgisinin BD tespitine katkısını sistematik biçimde analiz etmekte; Twitter ve Reddit'ten derlenen sosyal medya verileri üzerinde deney gerçekleştirmektedir.

Tüm modeller 0.90 ve üzerinde F1 skoru elde etmiş olmakla birlikte, aralarındaki performans farkı istatistiksel açıdan anlamlı bulunmamıştır. Çalışma, sosyal medya gönderilerinin BD tanısında güvenilirlik sınırlılıkları barındırdığına dikkat çekmektedir; çünkü kelime gömme yöntemleri, BD'nin temel özelliği olan uç duygu kararsızlığını yeterli ölçüde temsil etmekte zorlanmaktadır.

Amanat et al. (2022) Deep Learning for Depression Detection from Textual Data [11]

Bu çalışma, Twitter'dan derlenen metinsel verilerden depresyon tespitine yönelik klasik derin öğrenme yaklaşımlarından birini sunmaktadır. Araştırma, İki Gizli Katmanlı ve büyük bias faktörlü LSTM modelini, İki Yoğun Katmanlı RNN yapısıyla birleştiren bir mimari önermektedir. Kelime gösterimi için One-Hot kodlama ve Temel Bileşen Analizi (PCA) kullanılarak olası depresyon belirtileri ve duygu göstergeleri temsil edilmektedir.

Model, Twitter'dan scrape edilen depresyon veri seti üzerinde %99.0 doğruluk oranına ulaşarak diğer sıklık tabanlı derin öğrenme modellerini geride bırakmıştır. Önerilen yaklaşım, metinsel verilerden depresyonun erken tespitinde RNN ve LSTM'in etkinliğini açıkça ortaya koymaktadır.

Bu çalışma, transformer öncesi derin öğrenme yöntemlerinin yüksek doğruluk potansiyelini göstermesi açısından önemli bir referans noktası oluşturmaktadır. Bununla birlikte, %99'luk aşırı yüksek doğruluk oranı, veri setinin niteliği ve olası aşırı öğrenme (overfitting) konusunda dikkatli bir değerlendirme gerektirmektedir.

Tejaswini et al. (2024) Depression Detection from Social Media Text Analysis using NLP Techniques and Hybrid Deep Learning Model[12]

Bu çalışma, kelime dışı (OOV) temsil sorununu çözen ve sözlükte yer almayan kelimeleri de anlamlı biçimde modelleyebilen bir hibrit derin öğrenme mimarisi olan FCL (FastText-CNN-LSTM) modelini önermektedir. FCL mimarisinin üç temel bileşeni bulunmaktadır: OOV kelimeleri için anlamsal bilgiyle zenginleştirilmiş daha iyi metin temsili sağlayan FastText gömme yöntemi; global özellikleri hızlıca çıkaran CNN katmanı; yerel bağımlılıkları modelleyen LSTM katmanı.

Model, literatürde kullanılan gerçek dünya veri setleri üzerinde uygulanmış ve depresyon tespitinde güncel mevcut yöntemleri geride bırakan yüksek doğruluk

değerleri elde edilmiştir. Çalışma, sözlük dışı ifadeler ve argo içeren sosyal medya metninin doğru şekilde temsil edilmesinde FastText gömme yönteminin güçlü bir alternatif sunduğunu göstermektedir.

Bu araştırma; özellik mühendisliği ile derin öğrenme özellik çıkarımını birleştiren hibrit yaklaşımların, salt transformer tabanlı yöntemlere kıyasla belirli veri setlerinde rekabetçi performans sergileyebildiğini ortaya koymaktadır.

Hasan et al. (2026) Systematic Review of Machine Learning Approaches for Mental Health Detection Frontiers in Digital Health, 2026 [13]

Bu sistematik derleme, makine öğrenimi yöntemlerinin mental sağlık tespitinde nasıl kullanıldığını kapsamlı biçimde ele almaktadır. Çalışma, 2015-2025 yılları arasında yayımlanan ve sosyal medya verileriyle klinik metin verilerini kullanan ML tabanlı mental sağlık araştırmalarını sistematik olarak incelemektedir. Karar ağacı, destek vektör makineleri, rastgele orman ve gradyan artırma gibi klasik ML algoritmalarından transformer tabanlı derin öğrenme mimarilerine kadar geniş bir metodolojik yelpazeyi kapsayan bu derleme, alandaki metodolojik gelişimin anlamlı bir haritasını sunmaktadır.

Derleme, özellikle depresyon ve anksiyete tespitine yönelik çalışmalarda veri dengesizliği, aşırı uyum (overfitting) ve kültürlerarası genelleştirme sorunlarını ele almaktadır. Sistematik değerlendirme, transformer mimarilerinin (özellikle alana özgü ön eğitilmiş modellerin) klasik ML yaklaşımlarına kıyasla önemli ölçüde daha yüksek performans sergilediğini göstermektedir. Bununla birlikte, derleme veri gizliliği, önyargı ve klinik geçerlilik açısından açık araştırma sorularını da belgelemektedir. Bu makale, mevcut literatür taramamıza doğrudan katkı sağlayan, alan genelindeki yaklaşımları bütünleştiren önemli bir referans kaynağı niteliği taşımaktadır.

PLOS ONE (2025) Machine Learning Algorithms and NLP Techniques for Depression Detection in Social Media [14]

Bu çalışma, sosyal medya metinlerinden depresyon tespitinde makine öğrenimi algoritmaları ile doğal dil işleme tekniklerinin bir arada kullanımını karşılaştırmalı olarak incelemektedir. Çalışmada TF-IDF, Word2Vec ve BERT tabanlı gömme yöntemleri özellik çıkarımı için test edilmiş; Lojistik Regresyon, Naïve Bayes, SVM, Random Forest ve Gradient Boosting sınıflandırıcıları ise performans açısından karşılaştırmalı olarak değerlendirilmiştir. Reddit ve Twitter'dan elde edilen depresyon veri setleri üzerinde gerçekleştirilen deneyler,

BERT gömmeleriyle birleştirilen SVM ve Gradient Boosting modellerinin en yüksek doğruluk değerlerine ulaştığını ortaya koymuştur.

Çalışmanın en önemli katkısı, veri ön işleme aşamalarının (metni normalizasyon, durdurma kelimelerinin çıkarılması, ök sayım) model performansı üzerindeki etkisini sistematik biçimde analiz etmesidir. NLP boru hattı seçiminin klasik ML modelleriyle entegrasyonunda kritik rol oynadığını gösteren bu araştırma, hem metodolojik biçimde sağlam hem de pratik uygulamalara yönelik, erişilebilir bir çerçeve sunmaktadır. Q1 dergi sınıflaması, bu makalenin mevcut literatür taramamız için metodolojik referans değerini güçlendirmektedir.

Obagbuwa, I.C., Danster, S. & Chibaya, O.C. (2023). Supervised Machine Learning for Depression Sentiment Analysis in Social Media[15]

Bu çalışma, denetimli makine öğrenimi yöntemlerini sosyal medya metinlerindeki depresyon duygu analizine uygulamaktadır. Araştırma, Twitter ve Reddit'ten elde edilen gönderiler üzerinde duygu kutupluğu (pozitif/negatif/nötr) ile depresyon göstergelerini ilişkilendiren hibrit bir etiketleme çerçevesi geliştirmekte; Lojistik Regresyon, SVM ve Random Forest modellerini bu veri seti üzerinde karşılaştırmalı olarak değerlendirmektedir. Özellik olarak TF-IDF ve duygu sözcük sözlüğü (VADER, SentiWordNet) bir arada kullanılmış; Random Forest modeli en yüksek F1 skorunu elde etmiştir.

Çalışmanın temel katkısı, duygu analizi ile depresyon tespitini sistematik biçimde entegre etmesi ve bu entegrasyonun model doğruluğuna olan etkisini nicel olarak ortaya koymasıdır. Süpervizörlü öğrenme metodolojisine odaklanması ve duygu analizini depresyon tespiti ile ilişkilendiren sağlam değerlendirme çerçevesi sayesinde bu makale, klasik ML yöntemlerinin etkinliğini ve sentimentale dayalı özellik mühendisliğinin değerini gösteren önemli bir referans kaynağı niteliği taşımaktadır.

Kullanılan Veri Setlerinin Karşılaştırması

İncelenen çalışmalarda kullanılan veri setleri platform, boyut, etiketleme yöntemi ve hedef görev açısından aşağıdaki tabloda karşılaştırmalı olarak sunulmaktadır.

#	Veri Seti / Platform	Yazar(lar)	Bozukluk Tipi	Etiketleme Yöntemi	
1	Reddit (etiketli gönderiler)	Bin Saeed & Cha (2025)	Depresyon, Anksiyete, Bipolar, Şizofreni	Kural tabanlı etiket	
2	Twitter, Reddit	Zhou & Mohd (2025)	Depresyon	Sosyal medya gönderileri	
3	Reddit subredditlerinden	Karamat et al. (2025)	Çok sınıflı mental hastalık	Subreddit tabanlı etiket	
4	Reddit (4 seviyeli etiket)	Hussain et al. (2025)	Depresyon şiddeti	Min/orta/şiddetli	
5	Facebook (3 sayfa)	Islam et al. (2018)	Depresyon, Bipolar, Anksiyete	LIWC psikodilbilimsel özellikler	
6	Reddit benchmark veri seti	Wagay et al. (2025)	Genel mental hastalık	Benchmark standart etiket	
7	Reddit (4 subreddit)	Sanchez Rodriguez et al. (2026)	Anksiyete, Depresyon, Bipolar, BPD	Subreddit tabanlı etiket	
8	Reddit, MHC, Twitter Sentiment	Xin & Zakaria (2024)	Depresyon	3 farklı veri seti	
9	100+ çalışma derleme	Bin Tahir et al. (2025)	Genel depresyon	Literatür taraması	
10	Twitter, Reddit	Thamrin & Chen (2024)	Bipolar Bozukluk, Depresyon	Öz-beyan tabanlı tanı ifadeleri	

11	Twitter (scraped)	Amanat et al. (2022)	Depresyon	Scraped Twitter verisi	
12	Twitter, Reddit (gerçek dünya)	Tejaswini et al. (2024)	Depresyon	Standart veri seti	
13	Sistemantik derleme verileri	Hasan et al. (2026)	Genel mental sağlık	Literatür taraması	
14	Reddit, Twitter	PLOS ONE (2025)	Depresyon	Sosyal medya gönderileri	
15	Twitter, Reddit (2023)	Obagbuwa, I.C., Danster, S. & Chibaya, O.C. (2023).	Depresyon	Duygu + ML etiketleme	

Veri Seti Genel Değerlendirmesi: İncelenen çalışmaların büyük çoğunluğu (%75'ten fazlası) Reddit platformundan elde edilen veri setlerini kullanmaktadır. Bunun temel nedenlerinden biri, Reddit'in anonimlik sunan yapısının kullanıcıları mental sağlık deneyimlerini daha açık biçimde paylaşmaya teşvik etmesi ve bu platform üzerindeki mental sağlık subredditlerinin zengin, etiketlenebilir içerik üretmesidir. Twitter ise özellikle 280 karakter sınırının da etkisiyle kısa ve özlü metinlerin analizi için tercih edilmektedir. Facebook ise erken dönem çalışmalarda görünmekte, ancak güncel araştırmalarda giderek daha az tercih edilmektedir. Hedef görev açısından değerlendirildiğinde, çoğu çalışma ikili sınıflandırmayı (depresyon/depresyon değil) ele alırken daha az sayıda çalışma şiddet tahmini ya da çok sınıflı tanı gibi ileri düzey problemlere odaklanmaktadır.

Yöntemler ve Modellerin Hiyerarşik Karşılaştırması

İncelenen çalışmalarda kullanılan yöntemler üç ana kategoride hiyerarşik olarak değerlendirilebilir:

(1) Klasik Makine Öğrenimi, (2) Derin Öğrenme ve (3) Transformer Tabanlı Modeller.

Klasik Makine Öğrenimi

Alandaki en erken yaklaşımlar temsil eden klasik ML yöntemleri, psikodilbilimsel analizler ve TF-IDF, LIWC gibi yapı özellik çıkarım teknikleriyle birlikte kullanılmaktadır. Bu yöntemler; yorumlanabilirlik ve düşük hesaplama maliyeti açısından avantajlı olsa da kompleks dil yapılarını modelleme için sınırlı kalabilmektedir.

Model	Çalışma	Veri Seti	Özellikler	Performans
Decision Tree	Islam et al. (2018)	Facebook yorumları	LIWC psikodilbilimsel	En yüksek doğruluk (DT)
SVM	Islam et al. (2018)	Facebook yorumları	LIWC psikodilbilimsel	DT'nin altında
XGBoost + GloVe	Hussain et al. (2025)	Reddit	GloVe embedding	F1: 94.01
LR, RF, NB, KNN	Hussain et al. (2025)	Reddit	Word2Vec / GloVe	XGBoost'tan düşük

Derin Öğrenme Mimarileri

Derin öğrenme yöntemleri, kompleks örüntüleri otomatik olarak öğrenme kapasiteleriyle klasik ML'nin sınırlılıklarını aşmaktadır. Bu kategoride LSTM, BiLSTM ve bunların CNN ile hibrit kombinasyonları öne çıkmaktadır.

Model	Çalışma	Veri Seti	Özellikler	Performans
LSTM + RNN	Amanat et al. (2022)	Twitter	One-Hot + PCA	Doğruluk: %99.0
FastText + CNN + LSTM (FL-C)	Tehsin et al. (2024)	Twitter, Reddit	FastText embedding (OOV)	State-of-the-art geçiyor
BiLSTM + LSTM + Attention (DABN)	Bin Saeed & Cha (2025)	Reddit	Metin + zamansal	Doğruluk: %75.96 / F1: 0.7376

Transformer Tabanlı Modeller

Transformer mimarileri alandaki en yüksek performanslı yaklaşımları temsil etmektedir. Alana özgü ön eğitilmiş modeller (MentalBERT, MentalRoBERTa), genel amaçlı BERT modellerini geride bırakmaktadır.

Model	Çalışma	Veri Seti	Görev	Performans
BERT (fine-tuned)	Xin & Zakaria (2024)	Reddit, MHC, Tweets	Depresyon tespiti	Baseline BERT sonuçları
BERT-BiLSTM	Xin & Zakaria (2024), Zhou & Mohd (2025)	Reddit, Tweets	Depresyon tespiti	MentalBERT'i geçiyor
BERT-CNN	Xin & Zakaria (2024)	Reddit, MHC, Tweets	Depresyon tespiti	%98.2, %96.1, %100
MentalBERT (fine-tuned)	Sanchez Rodriguez et al.; Karam et al.	Reddit Subreddits	Çok sınıflı sınıflandırma	Ort. %82 - %92 doğruluk

Model	Çalışma	Veri Seti	Görev	Performans
MentaBERT (severity)	Hussain et al. (2025)	Reddit	Şiddet tespiti	F1: 97.31 (en yüksek)
MentaBERT + MentalBERT + CNN	Karam et al. (2025)	Reddit	Çok sınıflı tanı	Doğruluk: %92, F1: 0.92
MentaRoBERTaCaps	Wadgay et al. (2025)	Reddit benchmark	Mental hastalık sınıflandırması	Yüksek doğruluk
BioBERT / ClinicalBERT / MentalBERT	Thamrin & Chen (2024)	Twitter/Reddit	Bipolar bozukluk tespiti	$F1 \geq 0.90$

Hiyerarşik Genel Değerlendirme

İncelenen çalışmalar, mental sağlık tespitinde kullanılan yaklaşımların belirgin bir evrimsel ilerleme izlediğini göstermektedir. Aşağıda bu ilerlemenin boyutları değerlendirilmektedir:

- Klasik ML Yöntemleri (LR, SVM, DT):**
 Yorumlanabilirlik ve düşük hesaplama maliyeti açısından avantajlı olmakla birlikte, bu yöntemlerin performansı büyük ölçüde yapı özellik mühendisliğine bağlıdır.
- Derin Öğrenme Mimarileri (LSTM, BiLSTM, CNN-LSTM):**
 Bu modeller, metin dizilerindeki uzun vadeli bağıntıları otomatik olarak öğrenebilmektedir. BiLSTM, metni hem ileri hem de geri yönde işleyerek daha zengin bağlamsal temsiller oluşturmaktadır. Hibrit mimariler (CNN + LSTM, FastText + CNN + LSTM) bu kategoride öne çıkan yaklaşımlar olmuştur.
- Transformer Tabanlı Modeller (MentalBERT, MentalRoBERTa):**
 Bu kategoride alana özgü ön eğitilmiş modeller (MentalBERT,

MentalRoBERTa) en yüksek performansı sergilemektedir. Genel BERT modellerini geride bırakarak, mental sađlık alanına özgü dilsel örüntüleri öğrenmenin kritik önemini ortaya koymaktadır. Kapsül ađlarıyla hibrit edilen MentalRoBERTa-Caps, verimlilik-dođruluk dengesini optimize etmektedir.

Sonuç ve Genel Deđerlendirme

Bu literatür taraması, sosyal medya verilerini kullanarak mental sađlık bozukluklarının tespiti ve sınıflandırılmasına yönelik araştırmalardaki hızlı ilerlemeyi kapsamlı biçimde ortaya koymaktadır. İncelenen 15 çalışmanın genel bir deđerlendirmesi yapıldığında, alanın önemli bir evrimden geçtiđi görölmektedir: el yapımı özellik mühendisliđine dayanan klasik makine öğrenimi algoritmalarından, bağlamsal anlayışı son derece gelişmiş alana özgü transformer modellerine dođru belirgin bir dönüşüm yaşanmaktadır.

Veri setleri açısından deđerlendirildiğinde, Reddit platformundan elde edilen veriler araştırma topluluğunun tercihi haline gelmiştir. Bunun temel nedeni, platformun sunduđu anonimlik ortamının kullanıcıları mental sađlık deneyimlerini daha açık ve özgün biçimde paylaşmaya teşvik etmesidir. Bununla birlikte, etiketleme yöntemlerindeki farklılıklar (subreddit tabanlı etiketleme, öz-beyan ifadeleri vb.) çalışmalar arası karşılaştırmayı güçleştirmektedir.

Model performansı incelendiğinde, alana özgü transformer modellerinin (MentalBERT, MentalRoBERTa) genel amaçlı BERT modellerini ve diđer tüm yaklaşımları belirgin biçimde geride bıraktıđı görölmektedir. Hussain et al. (2025)[4] tarafından gerçekleştirilen kapsamlı karşılaştırmalı çalışmada MentalBERT, 97.31 F1 skoru ile depresyon şiddeti tespitinde en yüksek performansı elde etmiştir. Bu sonuç, alana özgü ön eğitim verilerinin kritik önemini açıkça vurgulamaktadır.

Kaynaklar

- [1] Q. Bin Saeed ve Y. Cha, “Multi-modal deep-attention-BiLSTM based early detection of mental health issues using social media posts”, *Sci. Rep.*, c. 15, sy. 1, s. 35152, Eki. 2025, doi: 10.1038/s41598-025-19141-0.
- [2] S. Zhou ve M. Mohd, “Mental Health Safety and Depression Detection in Social Media Text Data: A Classification Approach Based on a Deep Learning Model”, *IEEE Access*, c. 13, ss. 63284-63297, 2025, doi: 10.1109/ACCESS.2025.3559170.
- [3] A. Karamat, M. Imran, M. U. Yaseen, R. Bukhsh, S. Aslam, ve N. Ashraf, “A Hybrid Transformer Architecture for Multiclass Mental Illness Prediction Using Social Media Text”, *IEEE Access*, c. 13, ss. 12148-12167, 2025, doi: 10.1109/ACCESS.2024.3519308.
- [4] N. Hussain *vd.*, “Multi-Level Depression Severity Detection with Deep Transformers and Enhanced Machine Learning Techniques”, *AI*, c. 6, sy. 7, s. 157, Tem. 2025, doi: 10.3390/ai6070157.
- [5] Md. R. Islam, M. A. Kabir, A. Ahmed, A. R. M. Kamal, H. Wang, ve A. Ulhaq, “Depression detection from social network data using machine learning techniques”, *Health Inf. Sci. Syst.*, c. 6, sy. 1, s. 8, Ağu. 2018, doi: 10.1007/s13755-018-0046-0.
- [6] F. A. Wagay, Jahiruddin, ve Y. Altaf, “MentalRoBERTa-Caps: A capsule-enhanced transformer model for mental health classification”, *MethodsX*, c. 15, s. 103483, Ara. 2025, doi: 10.1016/j.mex.2025.103483.
- [7] I. Sánchez Rodríguez *vd.*, “Understanding mental health discourse on Reddit with transformers and explainability”, *Sci. Rep.*, c. 16, s. 6796, Oca. 2026, doi: 10.1038/s41598-026-35918-3.
- [8] C. Xin ve L. Q. Zakaria, “Integrating Bert With CNN and BiLSTM for Explainable Detection of Depression in Social Media Contents”, *IEEE Access*, c. 12, ss. 161203-161212, 2024, doi: 10.1109/ACCESS.2024.3488081.
- [9] W. B. Tahir, S. Khalid, S. Almutairi, M. Abohashrh, S. A. Memon, ve J. Khan, “Depression Detection in Social Media: A Comprehensive Review of Machine Learning and Deep Learning Techniques”, *IEEE Access*, c. 13, ss. 12789-12818, 2025, doi: 10.1109/ACCESS.2025.3530862.
- [10] S. A. Thamrin ve A. L. P. Chen, “Detection of Bipolar Disorder on Social Media Data Utilizing Biomedical, Clinical and Mental Health Domain Fine-Tuned Word Embeddings”, içinde *2024 IEEE 12th International Conference on Healthcare Informatics (ICHI)*, Haz. 2024, ss. 612-619. doi: 10.1109/ICHI61247.2024.00098.
- [11] “Deep Learning for Depression Detection from Textual Data”. Erişim: 06 Mayıs 2026. [Çevrimiçi]. Erişim adresi: <https://www.mdpi.com/2079-9292/11/5/676>

- [12] “Depression Detection from Social Media Text Analysis using Natural Language Processing Techniques and Hybrid Deep Learning Model | ACM Transactions on Asian and Low-Resource Language Information Processing”. Eriřim: 06 Mayıs 2026. [Çevrimiçi]. Eriřim adresi: <https://dl.acm.org/doi/full/10.1145/3569580>
- [13] M. J. Hasan *vd.*, “An in-depth exploration of machine learning methods for mental health state detection: a systematic review and analysis”, *Front. Digit. Health*, c. 7, Oca. 2026, doi: 10.3389/fdgth.2025.1724348.
- [14] G. Lorenzoni, C. Tavares, N. Nascimento, P. Alencar, ve D. Cowan, “Assessing ML classification algorithms and NLP techniques for depression detection: An experimental case study”, *PLOS ONE*, c. 20, sy. 5, s. e0322299, May. 2025, doi: 10.1371/journal.pone.0322299.
- [15] I. C. Obagbuwa, S. Danster, ve O. C. Chibaya, “Supervised machine learning models for depression sentiment analysis”, *Front. Artif. Intell.*, c. 6, Tem. 2023, doi: 10.3389/frai.2023.1230649.